

Tema 3 - Proyecto de clustering

¿Qué aprenderás?

En este punto vamos a trabajar un problema real de clustering sobre el dataset de E-commerce introducido en el tema 1. La idea es trabajar el proyecto de inicio a fin, es decir, desde el pre-procesado de los datos (se pueden aprovechar algunas de las técnicas aplicadas en el Tema 2, ya que el dataset es el mismo) hasta la obtención del modelo final ya entrenado y validado.

Plantearemos el problema de clustering a resolver, guiaremos el proceso a seguir para resolverlo y aportaremos diferentes técnicas que pueden ser utilizadas.

La realización de pruebas y la elección final del algoritmo, así como de las técnicas de pre-procesado y evaluación, será responsabilidad del alumno, y así lo deberá documentar y defender en la memoria y exposición final.



¿Sabías que...?

- ¿uno de los problemas más comunes en el clustering es la determinación del número óptimo de clústeres? Decidir cuántos clústeres son adecuados para los datos puede ser complicado y a menudo se utilizan métodos como el codo (elbow method) o el criterio de la silueta para ayudar en esta decisión.
- ¿la escala de los datos puede afectar significativamente los resultados del clustering? Si las variables tienen diferentes escalas, algunas pueden dominar el proceso de agrupamiento. Por eso, es común normalizar o estandarizar los datos antes de aplicar algoritmos de clustering.
- ¿la interpretabilidad de los clústeres puede ser un desafío? A veces, los clústeres resultantes pueden no tener un significado claro o ser difíciles de interpretar, lo que complica la toma de decisiones basada en ellos.



1.1. Planteamiento del problema

Planteamos un problema de segmentación de usuarios a partir del dataset de e-commerce introducido en el Tema 1. En dicho dataset tenemos diferentes variables que pueden ser significativas de cara a realizar un clustering de usuarios, con lo que es vital hacer un trabajo de limpieza de datos y creación de variables previo a aplicar un modelo de clustering.

Este problema no tiene una solución correcta, puesto que es un problema no supervisado. Por lo tanto, el objetivo es utilizar todo el conjunto de datos (sin separar un test set) para obtener agrupaciones de usuarios lo más significativas posibles, que a futuro nos pudieran servir para, por ejemplo y entre otras aplicaciones, crear un sistema de recomendación de productos para cada grupo de usuarios.

Debido a que en este caso no podemos evaluar de forma directa la calidad del modelo, se valorará tanto la calidad del pre-procesado y de las características creadas para el clustering, como el uso de técnicas complementarias como la reducción de dimensionalidad para la visualización de clusters, o la aplicación de métricas como el índice de silueta para evaluar la calidad de los mismos.

Por lo tanto, el planteamiento del problema de clustering es el siguiente:

- **Datos para entrenamiento:** Todo el dataset al completo.
- **Objetivo a conseguir:** Usuarios agrupados en un número finito de clusters (que definirá el alumno), demostrando diferencias significativas en el comportamiento entre ellos.

Este problema nos servirá para trabajar el pre-procesado de datos y las principales técnicas de clustering. En las siguientes secciones aportaremos guías para ambos procesos, y el alumno puede también tomar como referencia y guía las notebooks de ejemplo que se muestran en el apartado “Recursos y enlaces”.

La segmentación de usuarios es crucial para un retailer porque permite, principalmente, personalizar las estrategias de marketing y ventas. Al identificar y agrupar a los clientes según características comunes (como comportamiento de compra, demografía o preferencias), un retailer puede, por ejemplo, ofrecer promociones más relevantes para cada usuario, mejorar la comunicación con mensajes personalizados. Es muy habitual también que la segmentación de usuarios venga acompañada de un proyecto de sistemas de recomendación o de campañas de marketing digital, para aprovechar los insights que aporta.



1.2. Guía para el pre-procesado de datos

El dataset es el mismo que en el caso anterior, con lo que los primeros pasos del proceso (carga y análisis exploratorio) son análogos y ya los hemos realizado durante el proyecto de regresión del tema anterior.

De hecho, el orden de los pasos del pre-procesado es el mismo que se muestra en la guía del tema anterior, con lo que en este apartado vamos únicamente a centrarnos en aquellas partes y técnicas que son específicas para este problema de clustering, como por ejemplo la reducción de dimensionalidad, que es crucial para la visualización de clusters.

Seguimos por tanto la estructura de pasos de pre-procesado del tema anterior, entrando al detalle en aquellos elementos específicos de este problema de clustering:

- **Análisis exploratorio de los datos y su calidad:** Ya hemos entendido y observado los datos en el primer paso del proyecto anterior.
- **Limpieza de datos:** En este paso tenemos que tener en cuenta el problema que estamos trabajando para manejar valores faltantes, duplicados o erróneos. Así como en el tema anterior no era relevante, en este caso, ya que queremos hacer un clustering de usuarios, todas las filas en que el usuario no esté identificado (es decir, el valor de la columna CustomerID es null) deben ser eliminadas porque no aportan valor. Luego, el alumno debe revisar la lógica columna por columna y decidir por ejemplo si se queda con transacciones en que la descripción falta, puesto que puede tener una incidencia aunque no tan directa como en el caso de que falte el cliente. De igual manera, el alumno debe decidir y justificar si se queda o no con las transacciones canceladas, porque pueden aportar valor en cuanto a patrones de los usuarios, aunque también pueden distorsionar los patrones de compra.
- **Transformación de datos:** En este proyecto, este paso es vital, porque debemos convertir un dataset centrado en las transacciones en un dataset centrado en los usuarios. Para ello, el alumno debe seguir los siguientes pasos (análogos al tema anterior, pero con nuevas recomendaciones):
 - **Generación de nuevas variables:** Empieza diseñando nuevas variables que caractericen el comportamiento de los clientes a partir de sus compras. Por ejemplo, variables como el número total (y la media mensual) de compras, el número total de productos diferentes comprados, el valor medio (y el valor total, y mensual) de las compras, la frecuencia de compras (o tiempo entre



compra), los días (u horas) de la semana en que más compra, el país desde el que compra, etc. Creatividad al poder, cuantas más variables con sentido encontremos, más probabilidades hay de encontrar patrones significativos en nuestros clusters finales. Al finalizar este paso, debemos tener generado un nuevo dataset centrado en los usuarios, que será el que trataremos a partir de ahora.

- **Limpieza de datos:** Dado que tenemos un nuevo dataset, debemos hacer un nuevo proceso de análisis y limpieza de datos. Al haber hecho una limpieza previa sobre el dataset de e-commerce original y haber definido las variables nosotros mismos, no debería haber valores faltantes, con lo que el punto principal va a ser detectar y tratar los outliers que puedan haber aparecido. Podemos ejecutar este proceso de dos maneras, por un lado poniendo umbrales para eliminar los valores extremos del dataset respecto a algunas características (por ejemplo, eliminar aquellos clientes con un valor excesivamente alto de compras), o bien, aplicando un algoritmo de detección de anomalías, como por ejemplo Isolation Forest, para intentar encontrar un conjunto de outliers a eliminar (como aproximación, los outliers deben ser como mucho un 5-10% del total de los datos).
- **Escalado y normalización:** La normalización es clave puesto que los clusters funcionan con distancias entre los valores, con lo que debemos tener todas las características en la misma escala. De la misma manera, también nos será útil de cara a reducir la dimensionalidad del dataset (como veremos en el punto siguiente). Debemos por tanto escalar todas las variables numéricas, la recomendación sería utilizar alguno de los métodos habituales como por ejemplo Robust Scaling para escalar los valores de todas las características en un mismo rango
- **Codificación de variables categóricas:** Debemos codificar las variables categóricas que hayamos creado (como por ejemplo si hemos creado una variable relacionada con el país, o una variable relacionada con el día de la semana) con alguna de las técnicas habituales como One-Hot encoding.
- **Reducción de dimensionalidad:** Es muy probable que las variables que hayamos creado tengan una alta correlación, al provenir de un mismo dataset original. Podemos utilizar funciones de Pandas como corr para calcular la matriz de correlación entre variables y comprobarlo (valores por encima de 0,5 ya se



considera una correlación fuerte). Igualmente, aunque no exista dicha correlación, los métodos de clustering suelen funcionar mejor (y sobretodo, es más fácil visualizarlo) con pocas características, con lo que recomendamos realizar este proceso (además que así el alumno practica con este tipo de técnicas). Proponemos empezar con PCA, que es el algoritmo más utilizado y suele funcionar bien (aunque el alumno puede probar también cualquier otro método disponible como T-SNE, por ejemplo). Podemos probar varios valores para la dimensión final a la que reduciremos el dataset (hay técnicas que el alumno puede estudiar y probar para encontrar el valor óptimo, como calcular la varianza explicada acumulada) y, una vez realizada la transformación, debemos comprobar que la varianza explicada debe ser superior a un 60% en total para verificar que el dataset es significativo.

Al finalizar este paso, ya tenemos el dataset preparado para aplicar el modelo de regresión, podemos utilizarlo al completo puesto que no hay “test set” al ser un problema no supervisado.

1.3. Guía para el modelo de clustering

Una vez tenemos listo el dataset, podemos entrenar cualquier modelo de clustering para intentar obtener insights. Igual que para el problema de regresión, es habitual en el mundo laboral entrenar diferentes tipos de modelos, y para cada uno de ellos probar diferentes configuraciones de hiperparámetros y seleccionar la opción que da mejores resultados.

También proponemos al alumno que investigue y utilice métodos de estudio sobre los datos para determinar el número óptimo de clusters a buscar por el algoritmo (por ejemplo K-Means es altamente dependiente de este valor K), como por ejemplo el análisis de silueta o el método del codo (elbow).

Algunos modelos de clustering a probar podrían ser los siguientes:

- **K-Means:** Este es el modelo clásico para clustering, aunque depende mucho del parámetro K (el número de clusters a encontrar). Se puede utilizar Kmeans de la librería SK-Learn para implementarlo.
- **Clustering jerárquico:** Otro enfoque diferente de clustering, basado en ir conectando puntos en clusters sucesivamente, se puede utilizar AgglomerativeClustering de la librería SK-Learn para implementarlo.



- **Clustering por densidad (DBSCAN):** El tercer enfoque principal de clustering, basado en hacer clustering a partir de la densidad (es decir, un punto es denso cuando tiene poca distancia media respecto a los otros puntos) de los puntos, se puede utilizar DBSCAN de la librería SK-Learn para implementarlo.
- **Otros:** Adicionalmente, el alumno puede informarse sobre variantes de los modelos anteriores, como HDBSCAN (que combina conceptos del clustering jerárquico con el clustering por densidad de DBSCAN), o explorar y utilizar otros modelos de clustering como Gaussian Mixture Models (GMM) que no se hayan explicado en otros módulos.

Recomendamos probar al menos las tres primeras opciones, y se valorará también probar alguna adicional.

Para evaluar que los modelos de clustering ofrecen resultados significativos, podemos aplicar métricas de evaluación como el índice de silueta y el índice de Davies-Bouldin, aunque la mayor comprobación será realizar una visualización y comprobar que existe una separación entre los puntos.

Para hacer la visualización, debemos recortar los puntos a dimensión 2 o 3 (cogiendo las dimensiones que capturen más variabilidad de los datos) y recomendamos crear un scatterplot (o gráfico de puntos) en que cada cluster se pinte de un color, para comprobar visualmente que son clusters con sentido. También es interesante comprobar que tienen un tamaño parecido, puesto que no tiene mucho valor por ejemplo que un cluster contenga al 95% de los usuarios.

Recordemos que no hay una respuesta correcta, con lo que una vez hemos obtenido clusters suficientemente representativos, debemos interpretarlos e intentar entender qué comportamiento caracteriza a los usuarios dentro de un mismo cluster. Recomendamos realizar un análisis (con visualizaciones que puedan ayudar) de las características principales para cada cluster, y a partir de ahí intentar extraer conclusiones a partir de las características más diferenciales para extraer un título descriptivo para cada cluster, que ejemplifique qué tipo de usuarios están en él (esta la información que sería valiosa para el negocio).



Recursos y enlaces

- [SK-Learn: Modelos de clustering](#)
- [Kaggle: E-Commerce Customer Segmentation Example Notebook](#)
- [Kaggle: Clustering MethodsExample Notebook](#)

Conceptos clave

- **Clustering:** Un problema de clustering es un tipo de problema de análisis de datos en el que el objetivo es agrupar un conjunto de datos en subgrupos o clústeres, de manera que los elementos dentro de cada clúster sean más similares entre sí que con los elementos de otros clústeres. Un problema de clustering consiste en identificar y agrupar datos no etiquetados en clústeres basados en sus características y similitudes. A diferencia de los problemas de clasificación, donde las categorías están predefinidas, en el clustering no se conocen las etiquetas de los grupos de antemano.